

# מערכות לומדות תרגיל 1

שיר שבח 322407701

24 במרץ 2022

## 2. חלק תיאורטי

### 2.1 רקע מתמטי

#### 2.1.1 אלגברה לינארית

1.

נשים לב כי מטריצה אורתוגונלית מקיימת את התכונה  $\langle Av | Aw \rangle = \langle v | w \rangle$  לכל  $v, w \in V$  (לינארית 2). לכן עבור  $v \in V$  מתקיים:

$$\|Av\|^2 = \langle Av | Av \rangle = \langle v | v \rangle = \|v\|^2$$

לכן  $\|Av\| = \|v\|$ .

2.

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix}$$

כדי למצוא את  $V$ , אנו צריכים לחשב את הווקטורים העצמיים של  $A^T A$ .

$$W = A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

נמצא את הערכים העצמיים של המטריצה שמצאנו. ז"א נחשב  $(W - \lambda I)x = 0$  עבור  $x \in \mathbb{R}^3$ .

$$\begin{bmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{bmatrix} x = 0$$

נחשב את הדטרמיננטה של המטריצה הזאת כדי למצוא את הערכים העצמיים.

$$\begin{aligned}
\begin{vmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{vmatrix} &= (2-\lambda) \cdot \begin{vmatrix} 2-\lambda & -2 \\ -2 & 4-\lambda \end{vmatrix} + 2 \cdot \begin{vmatrix} 0 & 2-\lambda \\ 2 & -2 \end{vmatrix} \\
&= (2-\lambda)((2-\lambda)(4-\lambda) - 4) + 2 \cdot (-2 \cdot (2-\lambda)) \\
&= (2-\lambda)^2(4-\lambda) - 8(2-\lambda) \\
&= (2-\lambda)((2-\lambda)(4-\lambda) - 8) \\
&= (2-\lambda)(-6\lambda + \lambda^2) \\
&= \lambda(2-\lambda)(\lambda-6)
\end{aligned}$$

לכן הערכים העצמיים הם:  $\lambda_1 = 0, \lambda_2 = 2, \lambda_3 = 6$ .  
עבור כל ערך עצמי נמצא את הווקטור העצמי המתאים לו.  
עבור  $\lambda_1 = 0$ :

$$\begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 2 & 0 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 2 & 0 \\ 0 & 2 & -2 \\ 0 & -4 & 4 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 2 & 0 \\ 0 & 2 & -2 \\ 0 & 0 & 0 \end{bmatrix} \rightarrow \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 0 & 0 & 0 \end{bmatrix}$$

$$\begin{aligned}
x_1 + x_3 &= 0 \\
x_2 - x_3 &= 0
\end{aligned}$$

לכן

$$\begin{aligned}
x_1 &= -x_3 \\
x_2 &= x_3
\end{aligned}$$

לכן קיבלנו ווקטור עצמי  $\left\{ \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} \right\}$ . ננרמל ונקבל:  $\left\{ \begin{bmatrix} \frac{1}{\sqrt{3}} \\ \frac{-1}{\sqrt{3}} \\ \frac{-1}{\sqrt{3}} \end{bmatrix} \right\}$ .  
עבור  $\lambda_2 = 2$ :

$$\begin{bmatrix} 2-2 & 0 & 2 \\ 0 & 2-2 & -2 \\ 2 & -2 & 4-2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 0 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & 0 & 1 \\ 0 & 0 & -1 \\ 1 & -1 & 0 \end{bmatrix}$$

לכן

$$\begin{aligned}
x_3 &= 0 \\
x_1 &= x_2
\end{aligned}$$

$$\left\{ \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \\ 0 \end{bmatrix} \right\} \text{ ננרמל ונקבל: } \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \right\} \text{ לכן קיבלנו את הווקטור עצמי:}$$

עבור  $\lambda_3 = 6$ :

$$\begin{bmatrix} 2-6 & 0 & 2 \\ 0 & 2-6 & -2 \\ 2 & -2 & 4-6 \end{bmatrix} = \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix}$$

$$\left\{ \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} \right\} \text{ מחישוב numpy למציאת הבסיס למטריצה הנ"ל קיבלנו כי הווקטור עצמי:}$$

$$\left\{ \begin{bmatrix} \frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \end{bmatrix} \right\} \text{ ננרמל ונקבל: } \left\{ \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} \right\} \text{ לכן קיבלנו ווקטור עצמי:}$$

$$V = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{-1}{\sqrt{3}} \end{bmatrix} \text{ קיבלנו כי}$$

נשים לב שהערכים הסינגולריים של  $\Sigma$  הם שורש הערכים העצמיים של  $V$ .

$$\Sigma = \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix} \text{ לכן}$$

נחפש את  $U$  ע"י השיוויון  $AV = U\Sigma$ :

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{-1}{\sqrt{3}} \end{bmatrix} = U \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0 & \sqrt{2} & 0 \\ -\sqrt{6} & 0 & 0 \end{bmatrix} = U \begin{bmatrix} \sqrt{6} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} = U$$

ואז קיבלנו כי:

$$A = U\Sigma V^T = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{6} & \\ & \sqrt{2} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{3}} \\ \frac{2}{\sqrt{6}} & 0 & \frac{-1}{\sqrt{3}} \end{bmatrix}$$

**3.**

נשים לב כי  $C_0$  היא מטריצה ריבועית בעלת  $n$  ערכים עצמיים ו- $n$  ווקטורים עצמיים מנורמלים (נתון). משום שיש לה  $n$  ערכים עצמיים שונים ניתן לכתוב  $\lambda_1 > \dots > \lambda_n$  (אי-שיוויון חזק).

לכל  $b_0 \in V$ , ניתן לכתוב אותו כצירוף לינארי של ווקטורי הבסיס :

$$b_0 = a_1 v_1 + \dots + a_n v_n = \sum_{i=1}^n a_i v_i$$

נכפול את שני הצדדים ב- $C_0$ :

$$C_0 b_0 = a_1 C_0 v_1 + \dots + a_n C_0 v_n$$

לפי תכונת ווקטורים עצמיים נקבל:

$$C_0 b_0 = a_1 \lambda_1 v_1 + \dots + a_n \lambda_n v_n$$

נחזור על התהליך  $(C_0)^k$ :

$$\begin{aligned} C_0^k b_0 &= a_1 \lambda_1^k v_1 + \dots + a_n \lambda_n^k v_n \\ &= \lambda_1^k \left( a_1 v_1 + a_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \dots + a_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \end{aligned}$$

משום שאמרנו כי  $\lambda_1$  הוא הערך העצמי הגדול ביותר, נקבל שלכל  $i$  מ-1 ל- $n$ :  $\left( \frac{\lambda_i}{\lambda_1} \right)^k \rightarrow 0$  כאשר  $k$  שואף ל- $\infty$ .  
לכן:

$$\begin{aligned} C_0^k b_0 &= \lambda_1^k \left( a_1 v_1 + a_2 \left( \frac{\lambda_2}{\lambda_1} \right)^k v_2 + \dots + a_n \left( \frac{\lambda_n}{\lambda_1} \right)^k v_n \right) \\ &\xrightarrow[k \rightarrow \infty]{} \lambda_1^k a_1 v_1 \end{aligned}$$

לכן עכשיו נקבל כי

$$\begin{aligned} b_{k+1} &= \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{C_0^k b_0}{\|C_0^k b_0\|} \xrightarrow[k \rightarrow \infty]{} \frac{\lambda_1^k a_1 v_1}{\|\lambda_1^k a_1 v_1\|} \\ &= \frac{\lambda_1^k a_1 v_1}{|\lambda_1^k| \cdot |a_1| \|v_1\|} \end{aligned}$$

$\|v_1\| = 1$  כי הוא ווקטור עצמי מנורמל. ונקבל כי:

$$\lim_{k \rightarrow \infty} b_k = \lim_{k \rightarrow \infty} b_{k+1} = \frac{\lambda_1^k a_1 v_1}{|\lambda_1^k| \cdot |a_1|} = \pm v_1$$

## 2.1.2 חשבון רב משתנים

4. יהא  $x \in \mathbb{R}^n$  להיות ווקטור מתוקן ו- $U \in \mathbb{R}^{n \times n}$  להיות מטריצה אורתוגונלית מתוקנת. חשבו את היעקוביאן של הפונקציה  $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ :

$$f(\sigma) = U \cdot \text{diag}(\sigma) U^T x$$

נפתח את  $f$ :

$$U \cdot \text{diag}(\sigma) U^T x = \begin{bmatrix} | & | & | \\ u_1 & \cdots & u_n \\ | & | & | \end{bmatrix} \cdot \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \cdot \begin{bmatrix} \cdots & u_1^T & \cdots \\ \cdots & | & \cdots \\ \cdots & u_n^T & \cdots \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ | \\ x_n \end{bmatrix}$$

מתקיים:

$$\begin{bmatrix} \cdots & u_1^T & \cdots \\ \cdots & | & \cdots \\ \cdots & u_n^T & \cdots \end{bmatrix} \cdot \begin{bmatrix} x_1 \\ | \\ x_n \end{bmatrix} = \begin{bmatrix} \langle u_1, x_1 \rangle \\ | \\ \langle u_n, x_n \rangle \end{bmatrix}$$

$$\begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_n \end{bmatrix} \cdot \begin{bmatrix} \langle u_1, x_1 \rangle \\ | \\ \langle u_n, x_n \rangle \end{bmatrix} = \begin{bmatrix} \sigma_1 \langle u_1, x_1 \rangle \\ | \\ \sigma_n \langle u_n, x_n \rangle \end{bmatrix}$$

$$\begin{aligned} \begin{bmatrix} | & | & | \\ u_1 & \cdots & u_n \\ | & | & | \end{bmatrix} \cdot \begin{bmatrix} \sigma_1 \langle u_1, x_1 \rangle \\ | \\ \sigma_n \langle u_n, x_n \rangle \end{bmatrix} &= \begin{bmatrix} u_{11} & u_{1n} \\ u_{n1} & u_{nn} \end{bmatrix} \cdot \begin{bmatrix} \sigma_1 \langle u_1, x_1 \rangle \\ | \\ \sigma_n \langle u_n, x_n \rangle \end{bmatrix} \\ &= \begin{bmatrix} u_{11} \cdot \sigma_1 \langle u_1, x_1 \rangle + \dots + u_{1n} \cdot \sigma_n \langle u_n, x_n \rangle \\ \vdots \\ u_{n1} \cdot \sigma_1 \langle u_1, x_1 \rangle + \dots + u_{nn} \cdot \sigma_n \langle u_n, x_n \rangle \end{bmatrix} = \begin{bmatrix} f_1(\sigma) \\ \vdots \\ f_n(\sigma) \end{bmatrix} \end{aligned}$$

לכן בעצם נרצה למצוא את היעקוביאן של המטריצה הנ"ל.

$$\begin{bmatrix} \frac{\partial f_1(x)}{\partial x_1} & \cdots & \frac{\partial f_1(x)}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_n(x)}{\partial x_1} & \cdots & \frac{\partial f_n(x)}{\partial x_n} \end{bmatrix} = \begin{bmatrix} u_{11} \cdot \langle u_1, x_1 \rangle & \cdots & u_{1n} \cdot \langle u_n, x_n \rangle \\ \vdots & & \vdots \\ u_{n1} \cdot \langle u_1, x_1 \rangle & \cdots & u_{nn} \cdot \langle u_n, x_n \rangle \end{bmatrix} = \begin{bmatrix} u_1^T \cdot \langle u_1, x_1 \rangle & \cdots & u_n^T \cdot \langle u_n, x_n \rangle \\ \vdots & & \vdots \end{bmatrix}$$

5. השתמשו בכלל השרשרת כדי לחשב את הגרדיאנט של  $h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2$ .

$$\begin{aligned} h'(\sigma) &= \frac{1}{2} \cdot 2(f(\sigma) - y) \cdot f'(\sigma) \\ &= (f(\sigma) - y) \cdot f'(\sigma) \end{aligned}$$

6. חשבו את היעקוביאן של ה softmax function  $S: \mathbb{R}^k \rightarrow [0, 1]^k$

$$S(x)_j = \frac{e^{x_j}}{\sum_{l=1}^k e^{x_l}}$$

עבור כל קורדינטה  $i, j$  במטריצת יעקוביאן נחשב:  
במקרה בו  $i = j$

$$\begin{aligned} \frac{\partial S_i}{\partial x_i} \frac{e^{x_j}}{\sum_{l=1}^k e^{x_l}} &= \frac{e^{x_i} (\sum_k e^{x_k}) - (e^{x_i})^2}{\left(\sum_{l=1}^k e^{x_l}\right)^2} \\ &= \frac{e^{x_i}}{\sum_{l=1}^k e^{x_l}} \cdot \frac{(\sum_k e^{x_k}) - e^{x_i}}{\sum_{l=1}^k e^{x_l}} \\ &= S_i (1 - S_i) \end{aligned}$$

במקרה בו  $i \neq j$

$$\frac{\partial S_i}{\partial x_j} \frac{e^{x_i}}{\sum_{l=1}^k e^{x_l}} = \frac{0 - e^{x_i} e^{x_j}}{\left(\sum_{l=1}^k e^{x_l}\right)^2} = -(S_i) \cdot (S_j)$$

7. יהא  $f: \mathbb{R}^2 \rightarrow \mathbb{R}$  הפונקציה  $f(x, y) = x^3 - 5xy - y^5$ . חשבו את מטריצת ה-Hessian של  $f$ .

מטריצת ה-Hessian מוגדרת להיות:

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_d} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_d} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_d \partial x_1} & \frac{\partial^2 f}{\partial x_d \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_d^2} \end{bmatrix}$$

במטריצת הנ"ל,  $d = 2$ . לכן זו מטריצה  $2 \times 2$ .

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} = \begin{bmatrix} 6x & -5 \\ -5 & -20y^3 \end{bmatrix}$$

## 2.2 תורת האומדן

8. יהיו  $x_1, x_2, \dots \sim_{iid} P$  דגימות אינסופיות ב"ת בעלות התפלגות  $P$  בעלות תוחלת ושונות סופיים. הראו כי אומד הנראות  $\hat{\mu}_n = \frac{1}{n} \sum x_i$  המחושב עבור  $n$  הדגימות הראשונות הוא אומד נראות עקבי.

נרצה להראות כי עבור  $n$  הראשונים, ולכל  $\varepsilon > 0$ , מתקיים כי:

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\hat{\mu}_n - \mu| > \varepsilon) = 0$$

כאשר  $\mu$  הוא הערך האומד האמיתי של תוחלת הדגימות.

$$\begin{aligned} \mathbb{P}(|\hat{\mu}_n - \mu| > \varepsilon) &= \mathbb{P}\left(\left|\frac{1}{n} \sum x_i - \mu\right| > \varepsilon\right) \\ &= \mathbb{P}\left(\left|\sum x_i - n\mu\right| > n\varepsilon\right) \\ &\stackrel{\text{Chebyshev}}{<} \frac{\text{Var}(\sum x_i)}{(n\varepsilon)^2} = \frac{\sum \text{Var}(x_i)}{(n\varepsilon)^2} \\ &= \frac{n \cdot \sigma^2}{(n\varepsilon)^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

9.

נחשב עבור כל שורה במטריצה:

$$\begin{aligned} \log\_likelihood(\mu, \Sigma | x^{(i)}) &= \log \prod_{i=1}^m f_{X^{(i)}}(x^{(i)} | \mu, \Sigma) \\ &= \log \left( \prod_{i=1}^m \frac{1}{(2\pi)^{\frac{d}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left( -\frac{1}{2} (x^{(i)} - \mu)^T \Sigma^{-1} (x^{(i)} - \mu) \right) \right) \\ &= \sum_{i=1}^m \left( -\frac{p}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| - \frac{1}{2} (x^{(i)} - \mu)^T \Sigma^{-1} (x^{(i)} - \mu) \right) \end{aligned}$$

לכן קיבלנו כי כל המטריצה היא:

$$\log\_likelihood(\mu, \Sigma) = -\frac{mp}{2} \log(2\pi) - \frac{m}{2} \log |\Sigma| - \frac{1}{2} \sum_{i=1}^m (x^{(i)} - \mu)^T \Sigma^{-1} (x^{(i)} - \mu)$$


## 3. חלק מעשי

1.

$$(\mu\_ , \text{var}\_) = (9.955, 0.975)$$


.2

Question 2 - absolute distance between the estimated- and true value of the expectation



.3

Question 3 - empirical PDF of the Univariate Gaussian




.4

```
[ -0.02282878  -0.04313959   3.9932571  -0.02038981 ]  
[  0.91667608   0.16634444  -0.03027563   0.46288271 ]  
[  0.16634444   1.9741828   -0.00587789   0.04557631 ]  
[ -0.03027563  -0.00587789   0.97960271  -0.02036686 ]  
[  0.46288271   0.04557631  -0.02036686   0.9725373  ]
```

.5

Question 4 – log likelihood of multivariate gaussian





**.6**

$$F1 = -0.05$$

$$F2 = 3.97$$